



POLITECHNIKA WARSZAWSKA
WYDZIAŁ ELEKTRYCZNY
KIERUNEK INFORMATYKA STOSOWANA

Praca dyplomowa

Wykorzystanie sztucznych sieci neuronowych do prognoz kursu Wona
Południowokoreańskiego

Autor: Krzysztof Maciejewski

Opiekun: mgr inż. Marcin Kopyt

Warszawa, czerwiec 2021

Spis treści

1	Wstęp	1
2	Cel pracy	1
3	Rynek walutowy	2
3.1	Podstawowe informacje o rynku walutowym	2
3.2	Analiza techniczna	3
3.3	Analiza fundamentalna	4
4	Sztuczne sieci neuronowe	7
4.1	Podstawowe informacje o SSN	7
4.2	Sieci jednokierunkowe	9
4.3	Sieci rekurencyjne	9
5	Predykcja kursu Wona południowokoreańskiego	10
5.1	Wybór rodzaju prognozy	10

5.2	Dane wejściowe	10
5.3	Modele SSN	11
5.4	Wyniki	12
6	Wnioski	20
6.1	Dalsze kierunki badań	21
Bibliografia		23

1 Wstęp

Inwestowanie na rynkach finansowych z roku na roku staje się coraz popularniejsze na całym świecie. Tradycyjnie handel walutami był domeną międzynarodowych korporacji i zamożnych inwestorów, jednakże w ostatnich latach rynek Forex otworzył się również dla przeciętnych osób z mniejszym kapitałem. Z zalet rynku walutowego, które przede wszystkim cenią sobie inwestorzy, możemy wymienić płynność, dostępność całą dobę, niski próg wejścia czy możliwość wysokich zysków przy użyciu dźwigni finansowych.

Dużą wadą rynku walutowego jest jednak jego duża zmienność. Na rynek Forex wpływ ma bardzo wiele czynników, a tempo zmian w kursach sprawia, że trudno jest dokonać ich dogłębnej analizy. Mimo iż inwestorzy współcześnie dysponują dużym arsenalem różnych wskaźników oraz technik wizualizacji, aby wspomóc się w procesie decyzyjnym, to rynek Forex wciąż jest mało przewidywalny i większość osób traci pieniądze na swoich inwestycjach.

Duża zmienność tego rynku sprawia, że coraz więcej inwestorów zwraca się ku wykorzystaniu sztucznych sieci neuronowych. Pozwalają one na szybkie przetwarzanie dużej ilości danych i mogą stanowić istotną pomoc w podjęciu trafnej decyzji inwestycyjnej.

2 Cel pracy

Celem niniejszej pracy jest zbadanie możliwości zastosowania sztucznych sieci neuronowych do krótkoterminowej predykcji kursów na giełdzie walutowej. Badania przeprowadzono na podstawie danych o kursie wona Południowokoreańskiego względem dolara amerykańskiego. Sprawdzono wykorzystanie różnych wskaźników analizy technicznej i fundamentalnej oraz różne architektury sieci neuronowych, aby wyłonić model o największej dokładności predykcji dla nowych danych. Ostatecznie podjęto próbę oceny, czy wykorzystanie takiego modelu w praktyce umożliwi inwestorowi osiągnięcie lepszych wyników.

3 Rynek walutowy

W poniższym rozdziale opisano podstawowe informacje związane z funkcjonowaniem rynków walutowych. Opisano również różnice pomiędzy analizą techniczną i fundamentalną oraz omówiono najważniejsze czynniki mające wpływ na zmiany kursów walutowych.

3.1 Podstawowe informacje o rynku walutowym

Rynkiem walutowym, zazwyczaj określanym jako Forex, nazywamy całokształt transakcji wymiany walut, czyli transakcji kupna-sprzedaży jednej waluty za drugą [1]. W każdej transakcji walutowej przedmiotem obrotu są dwie waluty pochodzące z różnych krajów. W wyniku tych transakcji tworzą się kursy walutowe, które odzwierciedlają stosunek ceny między daną parą walut. Kurs walutowy stanowi zatem cenę jednostki pieniężnej wyrażoną w innej walucie.

Forex jest największym i najbardziej płynnym rynkiem na świecie, którego dzienne obroty przekraczają 5 bilionów dolarów [2]. Z tego względu stał się niezmiernie atrakcyjnym miejscem inwestycji i spekulacji traderów z całego świata. Szacuje się, że około 90% wszystkich transakcji na rynku Forex to transakcje spekulacyjne [2].


Forex jest przykładem rynku pozagiełdowego (ang. OTC-Over the counter market), co oznacza, że nie posiada fizycznego miejsca, a transakcje są dokonywane bezpośrednio pomiędzy uczestnikami rynku.

Na rynku Forex handluje się parami walutowymi. Pierwszą walutę w parze nazywamy walutą bazową, drugą nazywamy walutą kwotowaną. Cena pary walutowej (kwotowanie) oznacza ile waluty kwotowanej (drugiej w parze) możemy zakupić za jedną jednostkę waluty bazowej (pierwszej w parze).

Pip (Percentage in points) jest najmniejszą możliwą wartością, o jaką może zmienić się kurs danej pary walutowej. Większość walut jest kwotowana do czwartego miejsca po przecinku i to właśnie jednostkę 0.0001 nazywamy jednym pipsem.

Ceną ask nazywamy cenę po której można dokonać zakupu danej pary walutowej. Natomiast ceną bid nazywamy cenę po której można dokonać jej sprzedaży. Różnicę pomiędzy ceną ask i ceną bid określamy jako spread walutowy.

Zgodnie z definicją Banku Rozrachunków Międzynarodowych rynek walutowy dzie-



Rysunek 1: Graficzna prezentacja kwotowania pary walutowej na rynku Forex [3].

li się na dwa rynki [2]:

1. rynek bieżący (ang. Spot market),
2. rynek terminowy (ang. Forward market).

Wymiana na rynku spot opiera się na transakcjach natychmiastowych (do faktycznej wymiany waluty dochodzi w przeciągu dwóch dni od zawarcia umowy transakcyjnej, dla USD jest to jeden dzień [4]). To właśnie rynek spot jest popularny wśród inwestorów, z racji, że charakteryzuje go bardzo duża płynność i zmienność. Wymiana na rynku terminowych opiera się na transakcjach terminowych, to znaczy na transakcjach, które przewidują rozliczenie w terminie kilku miesięcy od daty zawarcia umowy po kursie terminowym uzgodnionym w momencie zawierania transakcji.

Dwie najpopularniejsze metody analizy par walutowych na rynku Forex to analiza techniczna i fundamentalna.

3.2 Analiza techniczna

Analiza techniczna skupia się przede wszystkim na cenie i wykresach cenowych, a opiera się na trzech filarach [5]:

1. Rynek dyskontuje wszystko - ignorujemy czynniki fundamentalne, zakładając że rynek kształtując cenę już wziął je pod uwagę.
2. Ceny podlegają trendom - zakładamy że cena porusza się zgodnie z trendem. Oznacza to, że kiedy trend jest już ustalony, to dużo bardziej prawdopodobne

jest że trend będzie kontynuowany niż odwrócony.

3. Historia się powtarza - korzystając z ruchów cenowych z przeszłości, można dostrzekać schematów (formacji cenowych) i dzięki temu zwiększyć prawdopodobieństwo przewidzenia kursu w przyszłości.

Wskaźniki analizy technicznej można podzielić na kilka kategorii. Trzy najpopularniejsze to [14]:

1. Momentum

Wskaźniki momentum bazują na aktualnym momentum ceny, to znaczy jej pędzie, szybkości i sile. Najbardziej znanym wskaźnikiem z tej kategorii jest RSI.

2. Wskaźniki trendu

Wskaźniki trendu, jak nazwa wskazuje, służą do określania aktualnego trendu. Z reguły są to wskaźniki okresowe liczone dla kilku odcinków wstecz w czasie.

3. Oscylatory

Pojęcie oscylator jest ogólną nazwą grupy wskaźników, które „oscylują” pomiędzy pewnymi wartościami, np. od 1 do -1. Mierzą one tempo zmian oraz szybkość ruchów notowań w stosunku do aktualnego poziomu cen. Przykładem wskaźnika z tej grupy jest wskaźnik MACD.

3.3 Analiza fundamentalna

Analiza fundamentalna w przeciwieństwie do analizy technicznej skupia się nie na samej cenie, ale również na wszystkich dostępnych danych makroekonomicznych, by finalnie oszacować właściwą wartość danego rynku. Poniżej opisane zostały najważniejsze czynniki ekonomiczne, mające wpływ na kształtowanie się kursów walutowych [6]:

- **Zmiany wzrostu gospodarczego**

Wzrost PKB danego państwa umacnia pozycję jego waluty. Również szybszy wzrost gospodarczy przyciąga zagranicznych inwestorów, co zwiększa popyt spekulacyjny. Do wskaźników najlepiej wyrażających wzrost gospodarczy zaliczamy [7]:

- PKB - produkt krajowy brutto mierzy wartość wszystkich dóbr i usług wytworzonych przez daną gospodarkę. Wzrost dynamiki zmian PKB w stosunku do poprzednich odczytów powinien oznaczać umocnianie się waluty danego kraju.
- PMI - wskaźnik aktywności finansowej stworzony przez Markit Group i Institute for Supply Management of financial activity. Dane potrzebne do uzyskania wskaźnika są pobierane z anonimowych ankiet, przesyłanych przez managerów z różnych dziedzin gospodarki. Ma on na celu odzwierciedlenie aktywności managerów nabywających różnego rodzaju dobra i usługi.
- Produkcja przemysłowa - wskaźnik ten śledzi dynamikę poziomu produkcji sektora przemysłowego.
- Bilans handlowy - wskaźnik ten wyraża różnicę dóbr eksportowanych i importowanych. Wysokie odczyty (nadwyżka handlowa) wskazują na silne zapotrzebowanie na daną walutę.
- Sprzedaż detaliczna - wskaźnik ten bada dynamikę zmian sprzedaży na poziomie detalicznym, a więc zwraca uwagę na wydatki konsumentów. Wyższe wydatki konsumentów oznaczają większe zyski przedsiębiorstw, które zwiększają swoje inwestycje potęgując przy tym potencjał wzrostu gospodarczego.
- Saldo obrotów bieżących – stanowi łączną miarę rozliczeń bieżących operacji (eksport i import produktów i usług oraz przepływy pieniężne) danej gospodarki z zagranicą. Podobnie jak w przypadku bilansu handlowego, nadwyżka pokazuje presję na kupno waluty danej gospodarki.

• Inflacja

Utrzymująca się inflacja może wpłynąć na spadek wartości waluty krajowej. Wzrost cen krajowych towarów i usług skutkuje spadkiem ich atrakcyjności na rynku eksportowym, co osłabia kurs waluty. Do pomiaru poziomu inflacji możemy wykorzystać wskaźniki:

- CPI (indeks cen konsumentów) - wskaźnik bada dynamikę wzrostu cen towarów i usług konsumpcyjnych.
- PPI (indeks cen producentów) - wskaźnik ten bada dynamikę wzrostu cen wśród producentów i gospodarstw rolnych.

• Stopy procentowe

Wzrost stóp procentowych skutkuje wzrostem wartości waluty krajowej z racji zwiększenia atrakcyjności rynku dla zagranicznego kapitału. Ich wysokość zależy od polityki monetarnej prowadzonej przez Bank Centralny.

- **Poziom bezrobocie**

Stopa bezrobocia jest jednym z najlepszych wskaźników do oceny ogólnej sytuacji gospodarczej w państwie.

Czynniki ekonomiczne				
	Czynnik	Waluta krajowa	Czynnik	Waluta krajowa
Wzrost gospodarczy	↑	↑	↓	↓
Inflacja	↑	↓	↓	↑
Stopy procentowe	↑	↑	↓	↓
Poziom bezrobocie	↑	↓	↓	↑

Rysunek 2: Zależności pomiędzy czynnikami ekonomicznymi, a walutą krajową [6].

Warto również wspomnieć, że na kursy walut na rynku Forex ma szereg innych czynników, które trudno jest jednoznacznie zmierzyć. Mowa tu na przykład o czynnikach politycznych takich jak stopień stabilność politycznej kraju, zmiany systemowe czy nastroje społeczne spowodowane polityką rządu. Również istotne na kształtowanie się cen na rynku są czynniki psychologiczne – większość inwestorów poddaje się emocjom podczas inwestowania na rynku Forex i ich decyzje nie zawsze będą miały logiczne uzasadnienie. Nie należy również wspomnieć o różnych sytuacjach jednorazowych, które nie sposób przewidzieć, jak choćby katastrofy naturalne.

4 Sztuczne sieci neuronowe


W tym rozdziale przedstawiono podstawowe informacje dotyczące budowy sieci neuronowych oraz ich działania.

4.1 Podstawowe informacje o SSN

Sztuczna sieć neuronowa składa się z wielu wzajemnie połączonych komórek liczących. Ich budowa i działanie wzrowane są na neuronach w biologicznym mózgu.


Neuron to rodzaj elektrycznie pobudliwej komórki zdolnej do przetwarzania i przewodzenia informacji w postaci sygnału elektrycznego. Zbudowany on jest z [8]:

- dendrytów, które odbierają informację pochodzącą z zakończeń aksonalnych innych neuronów;
- jądra komórki, które przechowuje i powiela informację genetyczną;
- aksonu, który przekazuje sygnał wejściowy dalej;
- synaps, które są łączą ze sobą neurony, tworząc sieć neuronową.



Rysunek 3: Budowa biologicznego neuronu [8].

Pierwszy matematyczny model neuronu został zaproponowany w 1943 roku przez McCullocha i Pittsa. Zapoczątkowało to nową dziedzinę badań – sztuczne sieci neuronowe, która od tego czasu jest stale rozwijana.



Rysunek 4: Schemat neuronu McCullocha-Pittsa [9].

Neuron McCullocha-Pittsa posiada wiele wejść i jedno wyjście. Każda wartość wejściowa mnożona jest przez przypisaną danemu wejściu wagę, po czym wartości te są sumowane w elemencie sumującym. Suma ważona sygnałów przekazywana jest do funkcji aktywacji, której wartość jest następnie zwracana na wyjście.

W zakresie przetwarzania informacji możliwości pojedynczego neuronu są stosunkowo niewielkie. W związku z tym podobnie jak w przypadku biologicznej sieci neuronowej, sztuczne neurony łączy się w grupy, które pozwalają na przeprowadzanie bardziej złożonych obliczeń i dzieli się je na warstwy [11].

Największą zaletą sieci neuronowych jest fakt, iż posiadają cechy zbliżone do cech ludzkiego mózgu. Są to:

- Adaptacyjność - uczenie się na podstawie doświadczeń,
- Zdolność uogólniania - kojarzenie faktów,
- Zdolność do interpretacji zjawisk, dla których dane są niekompletne/ błędne.

Z innych zalet SSN możemy wymienić równoległość przetwarzania informacji, niski koszt budowy czy odporność na błędy.


Sztuczne sieci neuronowe znajdują zastosowanie w rozpoznawaniu i klasyfikacji wzorców (przydzielaniu wzorcom kategorii), predykcji szeregów czasowych, analizie da-

nych statystycznych, odszumianiu i kompresji obrazu i dźwięku oraz w zagadnieniach sterowania i automatyzacji [10].

4.2 Sieci jednokierunkowe

Sieci jednokierunkowe to sieci neuronowe, w których nie występuje sprzężenie zwrotne, czyli pojedynczy wzorzec lub sygnał przechodzi przez każdy neuron dokładnie raz w swoim cyklu [10]. Najprostszą siecią neuronową jest pojedynczy perceptron progowy, opracowany przez McCullocha i Pittsa w roku 1943.

Najpopularniejszą siecią jednokierunkową jest perceptron wielowarstwowy (ang. Multilayer Perceptron, MLP). Sieć tego typu składa się zwykle z jednej warstwy wejściowej, kilku warstw ukrytych oraz jednej warstwy wyjściowej [12]. Perceptron wielowarstwowy w przeciwieństwie do perceptronu jednowarstwowego może być wykorzystywany do klasyfikowania zbiorów, które nie są liniowo separowalne.



Rysunek 5: Schemat perceptronu wielowarstwowego [13].

4.3 Sieci rekurencyjne

Mianem sieci rekurencyjnej określa się sieć, w której połączenia między neuronami stanowią graf z cyklami [10]. Oznacza to, że pomiędzy warstwą wyjściową i wejściową występuje sprzężenie zwrotne. Sprzężenie to ma symulować działanie ludzkiej pamięci skojarzeniowej (asocjacyjnej). Z tego względu sieci te są bardzo wydajne przy analizie sekwencji, gdyż są w stanie przechowywać informacje z przeszłości.

Najczęściej spotykanymi rekurencyjnymi sieciami neuronowymi są:

- sieć Hopfielda,

- maszyna Boltzman,
- sieć LSTM.

5 Predykcja kursu Wona południowokoreańskiego

W tym rozdziale opisano proces szukania modelu sztucznej sieci neuronowej, który najdokładniej przewiduje kurs Wona południowokoreańskiego względem dolara amerykańskiego ($KRW=X$)

5.1 Wybór rodzaju prognozy

Ostatecznie zdecydowano się na predykcję krótkoterminową, tzn. predykcję procentowej zmiany kursu na następny dzień. Oznacza to, że do badań użyte zostaną użyte jedynie informacje o kursach z poprzednich dni i wyliczone na ich podstawie wskaźniki analizy technicznej, z pominięciem analizy fundamentalnej. Decyzja ta wynika z małej częstotliwości znalezionych danych gospodarczych Korei Południowej, niewystarczającej do uzyskania wystarczającej ilości próbek do skutecznego wytrenowania sieci.


5.2 Dane wejściowe

Do badań wykorzystano dane z serwisu Yahoo Finance [15]. Pobrano historyczne dane $KRW=X$, czyli kursu wona południowokoreańskiego względem dolara amerykańskiego. Dane pochodziły z okresu 30.11.2003 (najstarsze dostępne dane) do 07.06.2021, miały częstotliwość dzienną i zawierały ceny high, low, open i close.

Na wykresie widać duży wzrost kursu w okolicach 2009 roku. Nagły spadek wartości KRW miał związek z ogólnoświatowym kryzysem gospodarczym w latach 2007-2009. Z racji, że dane z tego okresu mogłyby zaburzyć poprawne działanie tworzonych modeli, zdecydowano się wykorzystać jedynie dane od 01.01.2011, kiedy kurs już się ustabilizował.

Na podstawie tych danych wyliczone zostały dodatkowo jedne z popularniejszych wskaźników analizy technicznej [16]:

1. Average True Range - Średni Prawdziwy Zakres Zmiany



Rysunek 6: Kurs KRW=X dla pobranego okresu.

2. Bollinger Bands - Wstęga Bollinger'a
3. Momentum - Impet
4. Moving Average Convergence/Divergence - Zbieżność/Rozbieżność Średnich Ruchomych
5. Moving Average - Średnia Ruchoma/Ważona/Wykładnicza
6. Relative Strength Index - Indeks Siły Względnej
7. Stochastic Fast - Oscylator Stochastyczny Szybki
8. Stochastic Slow - Oscylator Stochastyczny Wolny

5.3 Modele SSN

Do badania wykorzystano sieć MLP oraz rekurencyjną sieć LSTM.

Stworzono 3 różne rodzaje modeli SSN [11]:

- C - SSN – na wejście sieci wprowadzono jedynie ceny zamknięcia z kilku poprzednich n dni;

- AT - SSN – na wejście sieci wprowadzono jedynie wskaźniki analizy technicznej;
- AT+C - SSN – na wejście sieci wprowadzono zarówno wskaźniki analizy technicznej, jak i ceny zamknięcia z n poprzednich dni.

Badano także:

- 2 funkcje aktywacji neuronów w warstwach ukrytych sieci MLP: RelU oraz tangens hiperboliczny.
- 2 różne liczby warstw ukrytych: 1, 2
- 2 różne warianty liczby neuronów w warstwach ukrytych: $n + 1$, $2n + 1$; gdzie n to liczba neuronów wejściowych.

Następujące parametry zastosowano we wszystkich modelach:

- optymalizator – ADAM (Adaptive Moment Estimation),
- funkcja kosztu - błąd średniokwadratowy (Mean Squared Error, MSE),
- funkcja aktywacji w warstwie wyjściowej - funkcja liniowa.

Łącznie przebadano 324 modeli sztucznych sieci neuronowych.

5.4 Wyniki

Wyniki badań poszczególnych sieci znajdują się w poniższych tabelach. Oznaczenie zmiennych jest następujące:


- $N = 2, 3, 4, \dots$ - liczba poprzednich cen zamknięcia uwzględnionych na wejściu;
- $hn = (n + 1), (2n + 1)$ - liczba neuronów w warstwach ukrytych, gdzie n to liczba wejść;
- $hl = 1, 2$ - liczba warstw ukrytych;
- $f = \tanh, \text{relu}$ - funkcja aktywacji dla neuronów w warstwach ukrytych (tangens hiperboliczny i RelU).

Wszystkie wyniki w tabelach są przeskalowane w celach prezentacyjnych (rzeczywiste wartości są w skali 10^{-5}).

Wyniki modeli opartych o ceny zamknięcia

N	hl=1, hn=(n+1)	hl=1, hn=(2n+1)	hl=2, hn=(n+1)	hl=2, hn=(2n+1)
2	16.2	4.95	6.26	6.52
3	12.23	4.15	5.25	4.65
4	8.61	5.97	4.55	4.66
5	13.21	11.55	4.17	3.8
6	4.47	4.57	5.88	4.35
7	11.28	9.32	7.13	6.83
8	5.62	7.8	4.44	4.85
9	5.17	6.12	5.71	5.03
10	5.47	5.45	5.13	5
11	7.09	10.59	4.96	16.17
12	5.18	9.54	11.64	8.42
13	9.62	5.75	14.26	3.96
14	8.03	5.33	9.55	5


Tabela 1: Wyniki dla modelu C-MLP z funkcją aktywacji w warstwach ukrytych: tangens hiperboliczny.



Rysunek 7: Wykres słupkowy wyników modeli C-MLP z funkcją aktywacji w warstwach ukrytych: tangens hiperboliczny.

N	hl=1, hn=(n+1)	hl=1, hn=(2n+1)	hl=2, hn=(n+1)	hl=2, hn=(2n+1)
2	5.24	6.67	6.82	5.24
3	5.47	4.25	4.19	4.64
4	4.71	7.44	4.52	4.52
5	3.99	3.99	4.65	4.81
6	4.74	4.36	4.84	4.63
7	6.75	7.46	6.01	6.08
8	5.07	5.1	5.33	5.31
9	5.43	6.89	4.5	4.69
10	4.97	4.82	4.89	4.74
11	4.72	4.55	5.02	5.8
12	5.01	5.45	4.54	5.66
13	5.37	5.05	4.7	4.44
14	12.95	11.93	6.21	4.72


Tabela 2: Wyniki dla modelu C-MLP z funkcją aktywacji w warstwach ukrytych: RelU.



Rysunek 8: Wykres słupkowy wyników modeli C-MLP z funkcją aktywacji w warstwach ukrytych: RelU.

N	hl=1, hn=(n+1)	hl=1, hn=(2n+1)	hl=2, hn=(n+1)	hl=2, hn=(2n+1)
2	5.53	6.91	5.24	5.24
3	3.98	4.56	4.18	4.16
4	4.97	4.92	4.52	4.58
5	4.18	4.06	4.06	4.06
6	4.51	4.74	4.73	4.89
7	7.03	7.39	6.34	6.74
8	5.16	5.13	5.29	5.39
9	4.76	4.55	4.88	4.58
10	5.17	5.51	4.97	4.95
11	6.12	6.18	5.61	5.19
12	4.99	4.89	5.25	5.09
13	4.32	4.27	4.5	4.55
14	4.9	5.67	4.75	4.95

Tabela 3: Wyniki dla modelu C-LSTM.



Rysunek 9: Wykres słupkowy wyników modeli C-LSTM.

Wyniki modeli opartych o wskaźniki AT


		hl=1, hn=(n+1)	hl=1, hn=(2n+1)	hl=2, hn=(n+1)	hl=2, hn=(2n+1)
MLP	tanh	1.92	1.87	1.49	1.71
	relu	1.81	1.82	1.98	1.78
LSTM	-	2.88	2.99	4.51	4.49

Tabela 4: Wyniki dla modeli AT-MLP oraz AT-LSTM.

Wyniki modeli opartych o ceny zamknięcia i wskaźniki AT

N	hl=1, hn=(n+1)	hl=1, hn=(2n+1)	hl=2, hn=(n+1)	hl=2, hn=(2n+1)
2	3.98	5.92	2.05	1.55
3	0.9	10	1.27	1.06
4	4.88	1.8	1.58	1.09
5	3.03	13.1	4.8	7.54
6	1.31	6.76	2.59	1.05
7	1.79	1.39	1.08	4.23
8	3.48	5.65	2.31	0.63
9	2.44	10.9	1.01	0.92
10	1.76	4.24	1.55	1.59
11	2.14	7.7	1.29	1.17
12	6.32	4.07	9.01	1.47
13	3.41	4.95	12.1	1.8
14	2.38	1.96	6.4	1.11


Tabela 5: Wyniki dla modelu C+AT MLP z funkcją aktywacji w warstwach ukrytych: tangens hiperboliczny.



Rysunek 10: Wykres słupkowy wyników modeli C+AT MLP z funkcją aktywacji w warstwach ukrytych: tangens hiperboliczny.

N	hl=1, hn=(n+1)	hl=1, hn=(2n+1)	hl=2, hn=(n+1)	hl=2, hn=(2n+1)
2	1.13	2.17	1.08	1.25
3	1.45	2.3	1.57	1.84
4	0.57	2.54	1.22	1.35
5	7.62	3.07	2.89	1.44
6	1.24	2.1	1.52	1.37
7	2.69	1.21	1.35	1.15
8	9.21	0.81	1.18	2.02
9	1.61	0.84	2.43	1.58
10	1.9	1.19	1.44	1.66
11	1.42	3.39	4.73	1.67
12	2.08	5.21	1.7	1.08
13	4	2.08	1.34	1.98
14	1.75	2.27	2.04	1.61


Tabela 6: Wyniki dla modelu C+AT MLP z funkcją aktywacji w warstwach ukrytych: ReLU.



Rysunek 11: Wykres słupkowy wyników modeli C+AT MLP z funkcją aktywacji w warstwach ukrytych: RelU.

N	hl=1, hn=(n+1)	hl=1, hn=(2n+1)	hl=2, hn=(n+1)	hl=2, hn=(2n+1)
2	4.43	3.59	5.12	5.01
3	2.89	3.05	4.01	4.74
4	3.18	2.75	5.85	4.28
5	4.48	2.66	3.54	3.68
6	2.79	3.55	5.51	3.72
7	3.39	3.75	5.64	4.7
8	3.05	3.13	4.62	4.61
9	2.99	3.01	4.43	2.84
10	3.92	3.26	4.19	3.85
11	3.45	3.21	4.8	3.63
12	3.88	3.44	4.94	3.51
13	2.88	4.08	3.67	3.13
14	4.03	2.7	4.07	3.72

Tabela 7: Wyniki dla modelu C+AT LSTM.



Rysunek 12: Wykres słupkowy wyników modeli C+AT LSTM.

6 Wnioski

Analizując tabele i wykresy można dojść do następujących wniosków:

- Najgorsze wyniki uzyskano dla modeli opartych jedynie o ceny zamknięcia z poprzednich dni. Ponadto ich wyniki były mocno nieregularne i zwracały różną dokładność po każdym wytrenowaniu. Zarówno sieć MLP, jak i LSTM osiągały podobne rezultaty.
- Wykorzystanie jedynie wskaźników analizy technicznej dawało umiarkowane wyniki. Modele te były dokładniejsze niż te oparte o ceny zamknięcia. Ponadto, sieci MLP dawały lepsze wyniki niż rekurencyjne LSTM, zwłaszcza przy dwóch warstwach ukrytych.
- Modele oparte o zarówno wskaźniki AT, jak i ceny zamknięcia okazały się najdokładniejsze. Tutaj również sieci MLP osiągały lepsze wyniki, niż sieci LSTM. Dla sieci MLP zwiększanie liczby warstw ukrytych i większe liczby neuronów w tych warstwach polepszało średnie rezultaty. Sieć LSTM z kolei lepiej sprawdzała się z jedną warstwą ukrytą, niż z dwoma.
- Najlepszy rezultat ($0.57 * 10^{-5}$) wśród wytrenowanych sieci osiągnął model typu AT+C MLP z:
 - jedną warstwą ukrytą,
 - 15 neuronami w warstwie ukrytej,
 - funkcją aktywacji RelU w warstwie ukrytej,
 - 4 poprzednimi cenami zamknięcia na wejściu.

Średnia zmiana wartości kursu na następny dzień w zbiorze testowym wynosiła 0.0046. Błąd na zbiorze testowym najlepszego modelu wynosi 0.0000057 i jest to zaledwie 0.12% tej wartości. Oznacza to że jesteśmy w stanie oszacować kurs na następny dzień z dokładnością do 0.12%. Taki model może stanowić zatem narzędzie do skutecznego prognozowania cen na rynku finansowym i stanowić pomoc dla spekulanta w podejmowaniu decyzji.

6.1 Dalsze kierunki badań

Badanie z powodzeniem może być kontynuowane, aby uzyskać jeszcze lepsze wyniki w predykcji cen na rynkach finansowych. Przykładowe dalsze kierunki badań to:

- Przetestowania innych modeli sieci neuronowych, np.: sieć rekurencyjna Hopfielda;
- Stworzenie modelu w oparciu o analizę fundamentalną do prognozy długoterminowej;
- Wykorzystanie większej ilości wskaźników analizy technicznej;
- Trenowanie sieci na kursach innych par walutowych, bądź danych z innych rynków finansowych;
- Przetestowanie innych architektur sieci (funkcji aktywacji, liczby neuronów w warstwach ukrytych, itp.);

Bibliografia

- [1] Michał Gruca, Aleksandra Woźna, *Rynek walutowy*, online: https://mfiles.pl/pl/index.php/Rynek_walutowy, dostęp: 04.06.2021.
- [2] X-Trade Brokers, *Forex - co to jest? Handel i inwestowanie na rynku Forex*, online: <https://www.xtb.com/pl/forex-kb>, dostęp: 04.06.2021.
- [3] SmartTrader.pl, *Jak czytać kwotowanie forex'owej pary walutowej?*, online: <https://smarttrader.pl/jak-czytac-kwotowanie-forexowej-pary-walutowej/>, dostęp: 04.06.2021.
- [4] Brian Dolan (2016), *Inwestycje walutowe dla bystrzaków*, tłum. Piotr Cieślak, Helion: Gliwice.
- [5] X-Trade Brokers, *Forex - co to jest? Handel i inwestowanie na rynku Forex*, online: <https://www.xtb.com/pl/forex-kb>, dostęp: 04.06.2021.
- [6] Kamil, *Czynniki wpływające na kursy walut*, online: <http://www.inwestycyjnyporadnik.pl/forex/czynniki-wplywajace-na-kursy-walut/>, dostęp: 04.06.2021.
- [7] Ludwik Czernecki, *Co wpływa na kursy walut? Lista wskaźników do zapamiętania*, online: <https://www.easysend.pl/blog/wskazniki-makroekonomiczne/>, dostęp: 04.06.2021.
- [8] sztuczna inteligencja.org, *Sztuczne sieci neuronowe*, online: <https://www.sztuczna-inteligencja.org.pl/kurs/sztuczna-inteligencja-dla-poczatkujacych/sztuczne-sieci-neuronowe/>, dostęp: 04.06.2021.
- [9] Wikipedia, *Neuron McCullocha-Pittsa*, online: https://pl.wikipedia.org/wiki/Neuron_McCullocha-Pittsa, dostęp: 04.06.2021.

- [10] Wikipedia, *Sieć neuronowa*, online: https://pl.wikipedia.org/wiki/Sie%C4%87_neuronowa, dostęp: 04.06.2021.
- [11] Michał Paluch, *Predykcja cen akcji na giełdzie z zastosowaniem modeli analityczno-neuronowych*, online: http://www.weeia.p.lodz.pl/wgrane_pliki/streszczenie_6.pdf, dostęp: 04.06.2021.
- [12] Wikipedia, *Perceptron wielowarstwowy*, online: https://pl.wikipedia.org/wiki/Perceptron_wielowarstwowy, dostęp: 04.06.2021.
- [13] Aref Hashemi Fath, Farshid Madanifar, Masood Abbasi, *Implementation of multi-layer perceptron (MLP) and radial basis function (RBF) neural networks to predict solution gas-oil ratio of crude oil systems*, online: <https://www.sciencedirect.com/science/article/pii/S2405656118301020>, dostęp: 04.06.2021.
- [14] Agnieszka Lipka, *7 najpopularniejszych wskaźników analizy technicznej*, online: <https://www.lynxbroker.pl/edukacja/popularne-wskazniki-analizy-technicznej/>, dostęp: 04.06.2021.
- [15] <https://finance.yahoo.com/currencies/>, dostęp: 04.06.2021.
- [16] Bossa.pl, *Analiza techniczna*, online: <https://bossa.pl/edukacja/analiza-techniczna/wskazniki>, dostęp: 04.06.2021.